

## **ETL Workshop 003**

**VICTOR ANDRES MARTINEZ PRECIADO**

Programa de ingeniería de datos e IA  
Facultad de ingeniería y ciencia básicas  
Universidad Autónoma de Occidente

**Daniel Felipe Romero Bernal**

2026

## Descripción de los Datos

Se integraron cinco archivos CSV correspondientes a los años 2015-2019. Cada archivo presentaba distintos nombres de columnas, por lo que fue necesario un proceso de normalización para unificarlos en un esquema común. La tabla siguiente resume las columnas estandarizadas utilizadas


| Campo normalizado | Descripción                              |
|-------------------|------------------------------------------|
| country           | Nombre del país                          |
| happiness_score   | Puntaje de felicidad (variable objetivo) |
| gdp_per_capita    | PIB per capita (logaritmico)             |
| social_support    | Soporte social percibido                 |
| life_expectancy   | Esperanza de vida saludable              |
| freedom           | Libertad para tomar decisiones de vida   |
| generosity        | Generosidad reportada                    |
| corruption        | Percepcion de corrupcion gubernamental   |
| year              | Año del reporte                          |

Tras la normalización y concatenación de los cinco archivos, el dataset consolidado contiene 782 registros y 10 columnas. Se identificó un único valor nulo en la columna corruption, el cual fue imputado con la mediana agrupada por año.

## Análisis Exploratorio de Datos (EDA)


### Distribución del Happiness Score

La distribución del Happiness Score presenta una forma aproximadamente normal con una leve asimetría positiva. La mayoría de los países se concentran entre los valores 4.5 y 6.5, con una media cercana a 5.4. Se observan pocos países en los extremos, siendo los valores más bajos (~2.8) correspondientes a naciones en conflicto o con alta inestabilidad política.



### Evolución temporal del score promedio


El score promedio global se mantuvo relativamente estable entre 2015 y 2019, oscilando entre 5.35 y 5.45. Se observa una caída notable en 2017 seguida de una recuperación sostenida hacia 2019, que alcanza el valor más alto del periodo. Las variaciones son pequeñas en términos absolutos, lo que sugiere que la felicidad global es un indicador de cambio lento.



### Matriz de correlación

El análisis de correlación revela que el PIB per cápita (0.79) y la esperanza de vida (0.74) son los factores más fuertemente asociados con el Happiness Score. El soporte social (0.65) y la libertad (0.55) muestran correlaciones moderadas-altas, mientras que la


generosidad (0.14) presenta una correlación casi nula, lo que anticipa su bajo poder predictivo en el modelo.



### Relación individual de cada feature con el score

Los scatter plots confirman visualmente las correlaciones observadas. El GDP per cápita, la esperanza de vida y el soporte social muestran tendencias lineales claras y consistentes, lo que valida su uso en un modelo de regresión lineal. La generosidad y la corrupción presentan mayor dispersión, indicando relaciones más complejas o no lineales.

Features vs Happiness Score



## Modelo de Machine Learning

Se entrenó un modelo de Regresión Lineal (Linear Regression de scikit-learn) utilizando los seis features seleccionados durante el EDA. El dataset fue dividido en 70% entrenamiento (547 registros) y 30% prueba (235 registros), con `random_state=42` para reproducibilidad.

### Coefficientes del modelo

| Feature         | Coefficiente | Interpretacion                  |
|-----------------|--------------|---------------------------------|
| freedom         | 1.6213       | Mayor impacto por unidad        |
| gdp_per_capita  | 1.0878       | Segundo mas importante          |
| corruption      | 1.0299       | Mayor impacto del esperado      |
| life_expectancy | 0.9739       | Muy cercano al GDP              |
| social_support  | 0.6292       | Aporte moderado                 |
| generosity      | 0.4048       | Menor aporte - esperado por EDA |
| Intercepto      | 2.2349       | -                               |


### Métricas de evaluación

| Métrica                     | Valor  | Interpretación                                         |
|-----------------------------|--------|--------------------------------------------------------|
| MAE (Error Absoluto Medio)  | 0.4486 | Error promedio aproximado a 0.45 pts en escala 2.8-7.8 |
| R2 (Coef. de determinacion) | 0.7266 | El modelo explica el 72.7% de la varianza              |

Un  $R^2$  de 0.73 es considerado un resultado sólido para un modelo lineal simple aplicado a datos socioeconómicos de múltiples años. El MAE de 0.45 es aceptable dado que el rango total del Happiness Score es de aproximadamente 5 puntos (2.8 a 7.8), representando un error relativo de aproximadamente el 9%.

### 4.3 Predicciones vs Valores reales

El scatter plot de predicciones vs valores reales muestra que los puntos siguen de cerca la línea de predicción perfecta (diagonal roja). La dispersión es simétrica y no presenta sesgos sistemáticos, lo que confirma que el modelo es apropiado para los datos.



## Pipeline de Streaming con Apache Kafka

---

El componente de streaming fue implementado con Apache Kafka, ejecutado mediante Docker con la imagen confluentinc/cp-kafka:7.6.0. El pipeline consta de dos scripts independientes:

### Producer (kafka/producer.py)

Lee el dataset procesado (happiness\_dataset.csv) registro por registro y lo serializa en formato JSON para enviarlo al topic happiness. Se introduce un delay de 50ms entre mensajes para simular transmisión en tiempo real. El producer transmite los 782 registros completos.

### Consumer (kafka/consumer.py)

Escucha el topic happiness de forma continua. Por cada mensaje recibido, carga el modelo entrenado (happiness\_model.pkl), construye un DataFrame con los features, genera la predicción del Happiness Score y almacena el resultado en la base de datos SQLite junto con el valor real y el error absoluto.

## Resultados y Conclusiones

---

El pipeline fue ejecutado exitosamente de extremo a extremo. Los 782 registros fueron transmitidos por Kafka, procesados por el consumidor y almacenados en la base de datos con sus respectivas predicciones. A continuación se presentan los hallazgos principales:

- **Normalización exitosa:** Los cinco CSVs con esquemas distintos fueron unificados en un dataset consistente de 782 registros sin pérdida de información relevante.
- **Modelo predictivo sólido:** La regresión lineal alcanzó un  $R^2$  de 0.727 y un MAE de 0.449, resultado competitivo para un modelo de primera línea sobre datos socioeconómicos multiuso.
- **Freedom como factor clave:** Contrario a lo que la correlación simple sugería, la libertad para tomar decisiones de vida resultó ser el feature con mayor coeficiente (1.62), superando incluso al GDP per cápita.
- **Generosidad de bajo impacto:** Como se anticipó en el EDA (correlación 0.14), la generosidad fue el feature de menor aporte predictivo, con un coeficiente de 0.40.
- **Streaming funcional:** El pipeline Kafka Producer-Consumer operó correctamente, procesando los 782 registros con un delay controlado de 50 ms entre mensajes.

Como trabajo futuro se podría explorar el uso de modelos no lineales (Random Forest, Gradient Boosting) para capturar relaciones más complejas entre las variables, así como la inclusión de la dimensión temporal (año) como feature adicional para mejorar el poder predictivo del modelo.